


АП_5. Техническая архитектура

5.1. Архитектура модулей и компонентов

5.1.1. Диаграмма модулей и компонентов MVP1, MVP 2



Перечень модулей и компонентов, включая микросервисы

№	Наименование	Назначение	Изменяемые данные (опционально)
1	Frontend Service	Статическое SPA приложение	

2	Backend Service (FastAPI)	Основной сервис для обработки, сохранения и автоматической отправки документов. Обеспечивает бизнес-логику системы, обработку запросов браузера к API, координацию работы с другими сервисами.	
3	PostgreSQL	Реляционная база данных для хранения структурированных данных системы: пользователи, документы, метаданные, настройки системы, история операций.	
4	S3 хранилище	Объектное хранилище для документов, файлов, изображений и других медиа-ресурсов. Обеспечивает долгосрочное хранение документов. При размещении файлов в S3 происходит их проверка Антивирусом Касперского	
5	OCR Service (Tesseract, Hugging Face)	Сервис для распознавания текста и обезличивания документов. Обеспечивает OCR функциональность и обработку персональных данных. Обработка персональных данных ведется на локальной модели GLiNER zero-shot NER	
6	Adapter микросервис	Микросервис предназначен для обработки запросов от Backend Service и создания гарантийных заявлений во внешней системе Techzor.	
7	Паспорт Помещения	Микросервис - мастер система по помещениям. Получает данные от CRM (kafka) и Техзор (через Adapter) по помещениям	

5.2. Перечень информационных потоков

№	Отправитель	Получатель	Примечание
1	Пользователь	Frontend Service	HTTPS запросы на загрузку статического приложения
2	Пользователь	Backend Service (FastAPI)	REST API запросы от интерфейса системы
3	Backend Service (FastAPI)	SSO	Авторизация и валидация токена доступа
4	Backend Service (FastAPI)	PostgreSQL	SQL запросы для сохранения и получения данных
6	Backend Service (FastAPI)	S3 хранилище	Загрузка и получение документов, файлов через S3 API
7	Backend Service (FastAPI)	Osmi AI	Отправка документов для AI обработки через внутренний API
11	Backend Service (FastAPI)	OCR Service	Передача документов для распознавания текста и обезличивания
12	OCR Service	Backend Service (FastAPI)	Отправка распознанных и обезличенных данных обратно
	OCR Service	S3 хранилище	Сохранение промежуточных данных
13	Backend Service (FastAPI)	Adapter	Отправка подготовленных документов через REST API
14	Adapter	Техзор (внешняя система)	Отправка подготовленных документов через REST API
15	Техзор (внешняя система)	Adapter	Ответ от внешней системы с результатами обработки
16	Паспорт Помещения	Kafka	Kafka - Информация об объектах недвижимости
17	1C CRM	Backend Service (FastAPI)	Получение обращения (Файлы АПО, обращения)

Инициатор сетевого взаимодействия	Компонента доступа сетевого взаимодействия	Параметры исходящего взаимодействия	Параметры входящего взаимодействия	Примечание
Пользователь	Frontend Service	--	HTTPS:443	Входящие запросы от пользователей через браузер
Frontend Service	Backend Service (FastAPI)	--	HTTP:8000	Внутреннее взаимодействие фронтенда с бэкендом
Backend Service (FastAPI)	PostgreSQL	--	TCP:5432 или 6433	Подключение к базе данных через JDBC/ODBC
Backend Service (FastAPI)	S3 хранилище	--	HTTPS:443 (S3 API)	Загрузка и получение файлов через S3 API

Backend Service (FastAPI)	Osmi AI	--	HTTP:3000	Вызов API для отправки документов на AI обработку в рамках одного кластера Kubernetes
Backend Service (FastAPI)	OCR Service	--	HTTP:8000	Отправка документов на OCR обработку
Backend Service (FastAPI)	Адаптер	--	HTTP:8000	Отправка дефектов в техзор

5.3. Сетевое взаимодействие

Контур DEV

№	Назначение	Источник/Source IP/ (IP-адрес / IP-сеть)	Имя источника / FQDN Source Name	Сеть источника / Source Net	Получатель / Destination IP / (IP-адрес / IP-сеть)	Имя получателя / FQDN Destination Name	Сеть получателя / Destination Net	Порт / Port	Протокол / Protocol
1	SSO								
2	1C CRM								
3	Kafka								
4	Техзор								

Контур TEST

№	Назначение	Источник/Source IP/(IP-адрес / IP-сеть)	Имя источника / FQDN Source Name	Сеть источника / Source Net	Получатель / Destination IP / (IP-адрес / IP-сеть)	Имя получателя / FQDN Destination Name	Сеть получателя / Destination Net	Порт / Port	Протокол / Protocol
1	Получение документов от CRM	10.177.173.19 10.177.173.22	dc-app043 hq-app10	VLAN 773	10.177.172.73 10.177.172.74 10.177.172.75	Kubernetes	TEST (VLAN 772)	443	HTTPS
2	Отправка обезличенного документа в ИИ для категоризации жалоб	10.177.172.73 10.177.172.74 10.177.172.75	kubernetes	TEST (VLAN 772)	через FQDN	https://llm7437.osmi-ai.ru/	Internet	443	HTTPS

Контур ПРОД

№	Назначение	Источник/Source IP/(IP-адрес / IP-сеть)	Имя источника / FQDN Source Name	Сеть источника / Source Net	Получатель / Destination IP / (IP-адрес / IP-сеть)	Имя получателя / FQDN Destination Name	Сеть получателя / Destination Net	Порт / Port	Протокол / Protocol
1	Получение документов от CRM	10.100.192.17 10.100.192.213 10.10.114.34	hq-app33 dc-app047 dc-app111	VLAN PROD	10.247.0.0/27, 10.248.0.0/27, 10.249.0.0/27	Kubernetes	Yandex Cloud	443	HTTPS
2	Отправка обезличенного документа в ИИ для категоризации жалоб	10.247.0.0/27, 10.248.0.0/27, 10.249.0.0/27	kubernetes	Yandex Cloud	через FQDN	https://llm7437.osmi-ai.ru/	Internet	443	HTTPS

5.4. Оборудование

Контур ПРОД

Система	Имя	IP	Сеть	CPU	RAM	OS	GPU RAM
ИС	Kubernetes	10.247.0.0/27,	Yandex Cloud	12	64		
		10.248.0.0/27,					
		10.249.0.0/27					
Tesla T4	Virtual Machine	10.247.0.0/27,	Yandex Cloud	4	16	ubuntu24	16Gb
		10.248.0.0/27,					
		10.249.0.0/27					

Контур TEST

Система	Имя	IP	Сеть	CPU	RAM	OS
ИС	Kubernetes	10.177.172.73	TEST (VLAN 772)	5	10	
		10.177.172.74				
		10.177.172.75				

Контур DEV

Система	Имя	IP	Сеть	CPU	RAM	OS
ИС	Kubernetes	10.177.170.107	DEV (VLAN 770)	5	10	
		10.177.170.108				
		10.177.170.151				

5.5. Публикация в Интернет

ИС предназначена для внутреннего использования.

Доступа к ИС из сети Интернет нет

5.6. Мониторинг

Мониторинг серверов (платформенный или legasy) осуществляется Группой сопровождения платформы разработки и прикладной инфраструктуры.

Метрики мониторинга

Метрики производительности

- Response Time: Время отклика (p50, p95, p99)
 - Алерт: p95 > 2000ms в течение 10 минут
- Error Rate: Процент ошибок от общего количества запросов
 - Алерт: > 5% ошибок в течение 5 минут
- Availability: Процент доступности сервиса
 - Алерт: < 99.9% в течение 15 минут

Метрики ресурсов

- CPU Utilization: Использование процессора
 - Алерт: > 80% в течение 10 минут
- Memory Usage: Использование памяти
 - Алерт: > 85% в течение 10 минут
- Disk I/O: Операции ввода/вывода на диск
 - Алерт: > 90% в течение 10 минут
- Disk Space: Свободное место на диске

- Алерт: < 15% свободного места
- Network I/O: Сетевая активность
 - Алерт: > 80% пропускной способности в течение 10 минут

Метрики базы данных

- Database Connections: Количество активных соединений
 - Алерт: > 80% от максимального пула соединений
- Query Performance: Время выполнения запросов
 - Алерт: Медленные запросы (> 5 секунд) в течение 5 минут
- Replication Lag: Задержка репликации
 - Алерт: > 10 секунд задержки репликации

Метрики очередей

- Queue Length: Длина очереди сообщений
 - Алерт: > 10000 сообщений в очереди
- Message Processing Rate: Скорость обработки сообщений
 - Алерт: < 100 сообщений/минуту в течение 10 минут
- Failed Messages: Количество неудачных сообщений
 - Алерт: > 100 неудачных сообщений в течение 5 минут

Метрики AI обработки

- AI Processing Time: Время обработки документов AI
 - Алерт: > 60 секунд на документ
- AI Queue Length: Длина очереди AI обработки
 - Алерт: > 100 документов в очереди
- AI Success Rate: Процент успешной обработки
 - Алерт: < 95% успешной обработки

Метрики хранилища

- S3 Storage Usage: Использование хранилища
 - Алерт: > 85% использованного пространства
- S3 Request Rate: Количество запросов к хранилищу
 - Алерт: > 1000 запросов/минуту

Требования для настройки алертов

- Критичность: Critical, Warning, Info
- Каналы уведомлений: Email, SMS, Telegram, PagerDuty
- Эскалация: Автоматическая эскалация при отсутствии реакции в течение 15 минут
- Группировка: Группировка похожих алертов для предотвращения флуда
- Время реакции: Critical - 5 минут, Warning - 15 минут

5.7. Средства журналирования

Аудит событий уровня конфигураций инфраструктуры проекта, размещенных в Яндекс Облаке, осуществляется при помощи сервиса Яндекс Аудит Trails, подключенному как агент к корпоративной системе SIEM. Перечень регистрируемых событий доступен по ссылке <https://yandex.cloud/ru/docs/audit-trails/concepts/events>

Требования к журналированию

Уровни логирования

- DEBUG: Детальная информация для отладки (только в DEV/TEST)
- INFO: Информационные сообщения о нормальной работе системы
- WARN: Предупреждения о потенциальных проблемах
- ERROR: Ошибки, требующие внимания
- CRITICAL: Критические ошибки, требующие немедленного вмешательства

Структура логов

- Timestamp: Время события в формате ISO 8601 (UTC)
- Level: Уровень логирования

- Service: Имя сервиса/компонента
- Request ID: Уникальный идентификатор запроса для трейсинга
- User ID: Идентификатор пользователя (если применимо)
- Message: Текст сообщения
- Context: Дополнительный контекст (метаданные, стек трейс для ошибок)

Компоненты журналирования

- Loki: Централизованное хранилище логов всех компонентов
- Prometheus: Сбор метрик, связанных с логированием (количество логов по уровням)
- Grafana: Визуализация и анализ логов через Loki datasource

Требования к хранению

- Retention: Хранение логов в течение 90 дней
- Архивирование: Автоматическое архивирование логов старше 30 дней
- Индексация: Индексация по timestamp, level, service, request_id для быстрого поиска

Безопасность логирования

- Обезличивание: В логах не должны отражаться любые персональные данные
- Шифрование: Шифрование логов при передаче и хранении
- Доступ: Контролируемый доступ к логам на основе ролей пользователей

Ответственный за соблюдение безопасности логирования - Владелец системы/РО

5.8. Средства бэкапирования

Названия серверов пока нет, оставляем название стендов

Сервер	Объект резервного копирования	Время полного резервного копирования	Срок хранения полного резервного копирования	Время Инкрементального резервного копирования	Срок хранения инкрементального резервного копирования	Ответственный	Комментарий
postgres-prod-01	PostgreSQL база данных	Ежедневно в 02:00	1 месяц	Каждые 6 часов	1 месяц	Группа сопровождения БД	Полные бэкапы с WAL архивированием
s3-prod-01	S3 хранилище документов	Еженедельно (воскресенье 03:00)	2 месяца	Ежедневно в 04:00	2 месяца	Группа сопровождения инфраструктуры	Бэкапы объектов хранилища
redis-prod-01	Redis данные и конфигурация	Ежедневно в 01:00	1 месяц	Каждые 4 часа	1 месяц	Группа сопровождения инфраструктуры	RDB снапшоты Redis
backend-prod-01	Конфигурация и данные приложения	Еженедельно (суббота 02:00)	1 месяц	Ежедневно в 03:00	1 месяц	Группа разработки	Конфигурационные файлы, настройки
osmi-ai-main-prod-01	Конфигурация AI сервиса, модели	Еженедельно (суббота 04:00)	2 месяца	Ежедневно в 05:00	2 месяца	Группа разработки	AI модели, конфигурации обработки
osmi-ai-worker-prod-01	Конфигурация AI воркера	Еженедельно (суббота 04:00)	2 месяца	Ежедневно в 05:00	2 месяца	Группа разработки	Конфигурации воркеров
ocr-prod-01	Конфигурация OCR сервиса, модели	Еженедельно (суббота 05:00)	2 месяца	Ежедневно в 06:00	2 месяца	Группа разработки	OCR модели, конфигурации
prometheus-prod-01	Метрики Prometheus	Ежедневно в 01:30	1 месяц	Каждые 6 часов	1 месяц	Группа сопровождения мониторинга	Бэкапы временных рядов метрик
loki-prod-01	Логи Loki	Ежедневно в 02:30	1 месяц	Каждые 6 часов	1 месяц	Группа сопровождения мониторинга	Бэкапы индексов и данных логов

5.9. Реализация и кодовая база

5.9.1. Используемое ПО и исходные коды

Структурная единица	Основное ПО	Дополнительное ПО	Исходные коды
Frontend Service	React	React	Git репозиторий: frontend-service
Backend Service	Python 3.11+, FastAPI 0.104+, Uvicorn	SQLAlchemy, Pydantic, Redis-py, boto3, Celery	Git репозиторий: backend-service
Adapter Service	FastApi		Git репозиторий: adapter-service
PostgreSQL	PostgreSQL 15+	pgAdmin, pg_stat_statements	Системная БД, миграции в репозитории backend-service
Redis	Redis 7.x	redis-cli, redis-sentinel	Конфигурация в репозитории infrastructure
S3 Storage	AWS S3 compatible	s3cmd, AWS CLI	Конфигурация в репозитории infrastructure
Osmi AI - Main			Git репозиторий: osmi-ai-main
Osmi AI - Worker			Git репозиторий: osmi-ai-worker
OCR Service	Python 3.11+, Hugging Face	FastApi, jinaai/jina-vlm	Git репозиторий: ocr-service
Grafana	Grafana 10.x	Grafana Loki datasource, Prometheus datasource	Конфигурация дашбордов в репозитории monitoring
Prometheus	Prometheus 2.x	Prometheus exporters, Alertmanager	Конфигурация в репозитории monitoring
Loki	Loki 2.x	Promtail, LogCLI	Конфигурация в репозитории monitoring
Infrastructure	Docker 24.x, Docker Compose 2.x	Kubernetes (опционально), Nginx	Репозиторий: infrastructure, docker-compose.yml
Kafka	Apache Kafka 3.6		

5.9.2. Регламент публикации и обновления

Регламент публикации и обновления

Публикация системы (обновление версии системы) осуществляется сотрудниками компании. Публикация и обновление происходит на базе следующего ПО:

- Docker: Контейнеризация приложений
- Docker Compose: Оркестрация контейнеров для локального развёртывания
- CI/CD Pipeline: Автоматизация сборки и развёртывания (GitLab CI/CD / Jenkins)
- Version Control: Git для управления версиями кода

Обновление системы на серверах происходит посредством обновления готового образа системы. Образ должен включать все необходимое для работы системы. Система может состоять из нескольких образов. Количеством образов не ограничивается. В образ должны быть включены первичные данные необходимые для начала работы системы.

Пакет обновления должен содержать:

- Образы системы:
 - frontend-service:latest - образ фронтенд сервиса
 - backend-service:latest - образ бэкенд сервиса
 - osmi-ai-main:latest - образ AI основного сервиса
 - osmi-ai-worker:latest - образ AI воркера
 - ocr-service:latest - образ OCR сервиса
 - postgres:15 - образ базы данных (опционально, может использоваться внешний)
 - redis:7 - образ Redis (опционально, может использоваться внешний)
- Схема запуска (docker-compose.yml):
 - Конфигурация всех сервисов
 - Настройки сетей и томов
 - Переменные окружения
 - Зависимости между сервисами
 - Настройки health checks
 - Конфигурация мониторинга и логирования

